

СПИСОК ОБОЗНАЧЕНИЙ И СОКРАЩЕНИЙ

В работе используются следующие обозначения и сокращения:

ε	—	пустое слово
Σ	—	конечный алфавит
Σ^*	—	множество всех строк над Σ
Σ^+	—	множество всех непустых строк над Σ
$\sigma_1 \circ \sigma_2$	—	композиция морфизмов $\sigma_1(\sigma_2(x))$
$\sigma^{-1}(x)$	—	прообраз слова x в σ
$\sigma _A$	—	ограничение морфизма σ на множество A
$im(\sigma)$	—	образ морфизма σ
$\mathcal{L}(S)$	—	язык, задаваемый S
LTL	—	локально тестируемый язык (locally testable language)
LTL-свойство	—	свойство, определяющее локально тестируемый язык
$SP(\sigma)$	—	класс строковых свойств, отвечающих стандартному морфизму σ
ДКА	—	детерминированный конечный автомат

ВВЕДЕНИЕ

В данной работе рассматривается и дополняется теоретическая составляющая подхода к абстрактной интерпретации строковых переменных, основанного на использовании систем линейных уравнений в словах определенного вида.

Представленный в статье [АН] подход к абстрактной интерпретации строк основан на идее отслеживания префиксов, суффиксов и подслов (инфиксов), что позволяет довольно эффективно проводить требуемые операциями над абстрактными строковыми объектами. С целью повышения точности анализа предлагается также отслеживать образы строк при некоторых строковых морфизмах. Этот подход позволит отслеживать непрерывные подстроки определенного вида: например, морфизм, отображающий символы-цифры в один символ, позволит сохранить информацию о непрерывных подстроках-числах, в то время как без отслеживания образов будет иметься информация только о разрозненном вхождении некоторых цифр в строку.

Абстракция образа строки при некотором морфизме представляется понятием строкового свойства. Именно набор строковых свойств образует строковый объект, выступающий абстракцией над строковой переменной. Однако одно и то же множество конкретизации могут описывать несколько строковых объектов, неравных между собой при явном сопоставлении компонент. Поэтому возникает задача нормализации строкового объекта в целом, что в том числе позволит более эффективно проводить статический анализ, поскольку некоторые гарантированные компоненты будут добавлены в рассмотрение на этапе нормализации.

Сопутствующей веткой исследования является рассмотрение морфизмов, которые целесообразно использовать в инструменте анализа в целом, поскольку они напрямую определяют взаимодействие строковых свойств во внутренней структуре строкового объекта. Предлагается рассматривать класс так называемых стандартных морфизмов — идемпотентных регрессивных алфавитных морфизмов.

Таким образом, целью работы является исследование нормализации строковых объектов, которое включает задачи:

1. Формализовать нормализацию строкового свойства.

2. Исследовать и описать решетки строковых свойств и решетки стандартных морфизмов.
3. Сформулировать концепции нормализации строкового объекта в целом.

1 Строковые свойства и строковые объекты

Уравнением в словах называется равенство вида $\Phi = \Psi$, где Φ и Ψ — слова над объединенным алфавитом $\Sigma \cup X$, где X — множество переменных.

В данной работе будем рассматривать системы линейных уравнений в словах вида

$$\left\{ \begin{array}{l} Z = c \\ Z = pW_0 \\ Z = W_1s \\ Z = X_1w_1Y_1 \\ Z = X_2w_2Y_2 \\ \vdots \\ Z = X_nw_nY_n \end{array} \right. , \quad (1)$$

где, возможно, отсутствуют уравнения некоторых типов, $c, p, s, w_1, w_2, \dots, w_n \in \Sigma^+$, $Z, W_0, W_1, X_1, X_2, \dots, X_n, Y_1, Y_2, \dots, Y_n$ — переменные. Легко видеть, что, если присутствует уравнение вида $Z = c$, то система имеет решение тогда, когда константы $p, s, w_1, w_2, \dots, w_n$ являются префиксом, суффиксом и подсловами константы c соответственно.

Вид уравнений в системе 1 описывает структуру строк, являющихся решениями системы относительно переменной Z : p задает общий префикс, s — общий суффикс, $w_1, w_2, \dots, w_n$ — подслова, которые одновременно встречаются в строке-решении.

Уравнение вида $Z = c$ будем называть константным уравнением, $Z = pW_0$ — уравнением на префикс, $Z = W_1s$ — на суффикс, $Z = XwY$ — на инфикс.

Приведем несколько определений, которые будут использоваться в дальнейшем.

Отметим, что на протяжении всей работы будет рассматриваться фиксированный алфавит Σ , оснащенный линейным порядком $\leq$ и минимальным элементом $\delta_\emptyset$.

Определение 1. Морфизм строк $\sigma : \Sigma^* \rightarrow \Sigma^*$ называется *алфавитным* (или *неудлиняющим по длине, length-non-increasing*), если образ любого символа алфавита Σ — либо символ, либо пустое слово ε .

Определение 2 (стандартный морфизм). Будем рассматривать морфизмы σ , задаваемые разбиением алфавита Σ на подмножества $\Sigma_1, \dots, \Sigma_k, \Sigma_\varepsilon$ при $|\Sigma_i| > 1$, которые идемпотентны, не увеличивают букву относительно алфавитного порядка и сохраняют это разбиение, то есть

$$\forall \delta \in \Sigma_i \quad \sigma(\delta) \leq \delta \wedge \sigma(\sigma(\delta)) = \sigma(\delta) \wedge \sigma(\delta) \in \Sigma_i, \quad \forall \delta \in \Sigma_\varepsilon \quad \sigma(\delta) = \varepsilon.$$

Такие морфизмы будем называть *стандартными*.

В стандартном морфизме для $\delta \in \Sigma_i$ значение $\sigma(\delta)$ — минимальный относительно $\leq$ символ в Σ_i .

Определение 3. Для стандартных морфизмов σ_1 и σ_2 полагаем $\sigma_1 \preceq \sigma_2$ тогда и только тогда, когда $\sigma_2 \circ \sigma_1 = \sigma_2$.

Для любого неудлиняющего морфизма θ с условием $\forall \delta \theta(\delta) \preceq \delta$ неподвижная точка θ^* является стандартным морфизмом относительно некоторого разбиения алфавита.

Определение 4 (Строковое свойство). Зафиксируем некоторый алфавит Σ , будем иметь целью описание некоторых подмножеств моноида Σ^+ .

Строковым свойством (String Property, SP) назовем пару (σ, E) , где $\sigma : \Sigma^* \rightarrow \Sigma^*$ — стандартный морфизм, E — система линейных уравнений в словах над алфавитом $\Sigma' = \text{im}(\sigma|_\Sigma) \setminus \{\varepsilon\}$ вида, представленного в системе 1.

Каждое строковое свойство задает в Σ^* некоторый язык $L_{\sigma, E} = \mathcal{L}((\sigma, E)) = \sigma^{-1}(\mathcal{L}(E))$. Здесь $\mathcal{L}(E)$ — Z -проекция множества решений системы E как языка над Σ' .

Определение 5 (абстракция и конкретизация). Пусть S — множество конкретных значений данных, а $\langle L^\Delta, \sqcup, \sqcap \rangle$ — решётка абстрактных значений. *Абстракцией* называется функция $\alpha : 2^S \rightarrow L^\Delta$, сопоставляющая множеству конкретных значений обобщающее их абстрактное значение. *Конкретизацией* называется функция

$\gamma: L^\Delta \rightarrow 2^S$, сопоставляющая абстрактному значению множество описываемых им конкретных значений.

Пара (α, γ) задаёт *связь Галуа* (Galois connection), если для любого $A \in 2^S$ выполнено $A \subseteq \gamma(\alpha(A))$ и для любого $\rho \in L^\Delta$ выполнено $\rho \preceq \alpha(\gamma(\rho))$.

В случае строкового свойства (σ, E) роль множества конкретных значений играет 2^{Σ^*} , а абстрактным значением выступает само строковое свойство; его конкретизация — задаваемый им язык $L_{\sigma, E}$.

Конкретизацию строкового свойства будем также обозначать $\gamma((\sigma, E)) = L_{\sigma, E}$.

Зафиксируем стандартный морфизм σ и рассмотрим все строковые свойства (σ, E_1) и (σ, E_2) с этим морфизмом. Между ними естественно вводится порядок по включению конкретизаций:

$$(\sigma, E_1) \preceq (\sigma, E_2) \iff \gamma((\sigma, E_2)) \subseteq \gamma((\sigma, E_1)).$$

Совокупность таких свойств с фиксированным σ обозначим $SP(\sigma)$.

Для статического анализа строковых переменных будем использовать абстрактный домен строковых объектов — объектов, содержащих в себе строковые свойства как компоненты.

Среди стандартных морфизмов выделим два канонических:

- тождественный морфизм $\text{id}: SP = (\text{id}, E)$ абстрагирует *значение* строки;
- морфизм $\sigma_{\forall \rightarrow \delta_\emptyset}$, склеивающий весь алфавит в выделенный символ $\delta_\emptyset$: $SP = (\sigma_{\forall \rightarrow \delta_\emptyset}, E)$, задаёт унарное представление нижней границы *длины* строки.

Определение 6 (абстрактный строковый объект). Зафиксируем алфавит Σ и конечный набор стандартных морфизмов $\sigma_1, \dots, \sigma_n$. *Абстрактным строковым объектом* называется кортеж

$$\nu = \langle \text{val}(\nu), \text{len}(\nu), \text{prop}_1(\nu), \dots, \text{prop}_n(\nu) \rangle,$$

в котором $\text{val}(\nu) \in \text{SP}(\text{id})$, $\text{len}(\nu) \in \text{SP}(\sigma_{\forall \rightarrow \delta_\emptyset})$ и $\text{prop}_i(\nu) \in \text{SP}(\sigma_i)$ для каждого $i = 1, \dots, n$. Его конкретизацией называется пересечение конкретизаций всех компонент:

$$\gamma(\nu) = \gamma(\text{val}(\nu)) \cap \gamma(\text{len}(\nu)) \cap \bigcap_{i=1}^n \gamma(\text{prop}_i(\nu)).$$

Определение 7. *Абстрактным доменом строковых объектов* называется редуцированное произведение полурешёток строковых свойств

$$\text{SOB} = \text{SP}(\text{id}) \otimes \text{SP}(\sigma_{\forall \rightarrow \delta_\emptyset}) \otimes \bigotimes_{i=1}^n \text{SP}(\sigma_i),$$

$\text{SP}(\text{id})$ — домен значения строки, $\text{SP}(\sigma_{\forall \rightarrow \delta_\emptyset})$ — домен длины (унарное представление), а $\bigotimes_{i=1}^n \text{SP}(\sigma_i)$ — необязательное редуцированное произведение остальных свойств, задаваемых стандартными морфизмами $\sigma_1, \dots, \sigma_n$.

Конкретизация задаётся пересечением конкретизаций компонент (см. определение 6).

2 Нормализация свойства

Определение 8. Словарем будем называть множество строк $D = \{w_1, w_2, \dots, w_n\}$, обладающее свойством: никакая строка этого множества не является подстрокой другой строки из D .

Определение 9. Расширенным словарем будем называть тройку множеств $D = \langle P, S, I \rangle$, где P — множество префиксов, S — множество суффиксов, I — множество инфиксов и при этом:

- I удовлетворяет определению словаря;
- строки из I не являются подстроками (возможно, несобственными) строк из P или S ;
- P и S — пустые множества или множества из одного элемента.

Строки, обозначающие префикс и суффикс расширенного словаря будем сопровождать маркерами начала и конца строки, таким образом они будут иметь

вид $^{\wedge}w$ и $w^{\$}$ соответственно. Расширенный словарь будем коротко записывать как множество $D = \{^{\wedge}p, s^{\$}, w_1, w_2, \dots, w_n\}$.

Таким образом, расширенный словарь, не имеющий префиксов и суффиксов, является словарем, и вышеобозначенная запись в виде множества строк объединяет определения словаря и расширенного словаря. Поэтому далее под словарем будет подразумеваться расширенный словарь, если явно не указано отсутствие ограничения на наличие префиксов и суффиксов.

Условия, отличающие словарь от обычного множества (с выделенным, возможно, суффиксом и префиксом), необходимы, чтобы однозначно сопоставить язык, задаваемый словарем, и сам словарь.

Определение 10. Языком словаря D будем называть множество строк

$$\mathcal{L}(D) = \{a \in \Sigma^+ \mid \forall w_i \in I \quad a \in p\Sigma^* \cap \Sigma^*s \cap \Sigma^*w_i\Sigma^*\}.$$

Многообразие языков, задаваемых расширенными словарями, представляет собой класс языков, задаваемых системами линейных уравнений вида 1 без уравнений $Z = c$ (при фиксированном алфавите).

Отметим, что рассматриваемые в данной работе языки входят в некоторый подкласс регулярных языков, что можно использовать для обоснования их некоторых свойств.

Определение 11. Язык $L \subseteq \Sigma^+$ называется *строго k -тестируемым* (*strictly k -testable*), если существуют число $k > 0$ и четыре множества U, V, W, F такие, что

$$F, U, V \subseteq \Sigma \cup \Sigma^2 \cup \dots \cup \Sigma^{k-1}, \quad W \subseteq \Sigma^k,$$

и

$$L = [(U\Sigma^* \cap \Sigma^*V) \setminus \Sigma^*W\Sigma^*] \cup F.$$

Язык, строго k -тестируемый для некоторого $k > 0$, называется *строго локально тестируемым* (*strictly locally testable, SLT*).

Определение 12. Язык $L \subseteq \Sigma^+$ называется *k -тестируемым* (*k -testable*), если он является булевой комбинацией строго k -тестируемых языков.

Язык называется *локально тестируемым* (*locally testable, LT*), если он k -тестируем для некоторого $k > 0$.

Интерес представляют языки, задаваемые системой уравнений 1, а именно языки вида

$$L = \bigcap_{i=1}^n L_i, \text{ где } L_i \text{ имеет вид либо } \Sigma^* w_i \Sigma^*, \text{ либо } w_i \Sigma^* \text{ либо } \Sigma^* w_i, w_i \in \Sigma^*. \quad (2)$$

Поскольку язык вида $\Sigma^* \setminus \Sigma^* w_i \Sigma^*$ локально тестируем (более того, строго локально тестируем), то $\Sigma^* w_i \Sigma^*$ также локально тестируем. Очевидно, что $w_i \Sigma^*$ и $\Sigma^* w_i$ также строго локально тестируемы, из чего следует, что L , представленный как пересечение этих компонент — LT-язык.

Проекция решения на переменную Z позволяет кодировать некоторое множество строк, поскольку из системы известны ограничения на их префиксы, суффиксы и инфиксы. Несмотря на то, что Z -проекция решения — регулярный язык, при возрастании числа уравнений возрастает трудоемкость построения для него альтернативного представления, поэтому хранение словаря — набора строк из уравнений системы — является наиболее эффективным.

Например, пустое множество решений может задаваться любой системой с набором противоречащих друг другу уравнений, что легко проверяется анализом константных строк, входящих в уравнения, но трудоемко, если использовать ДКА для каждого уравнения и их пересечения.

Заметим, что представление языка в виде словаря с присоединенной альтернативой в виде единственной строки эквивалентна представлению в виде системы уравнений вида 1 при фиксированном алфавите.

Определение 13 (Задача внутренней нормализации строкового свойства). Представление языка $L \subseteq \Sigma^*$ $L = \bigcap_{i=1}^n L_i$ (L_i имеет вид $\Sigma^* w_i \Sigma^*$ или $w_i \Sigma^*$ или $\Sigma^* w_i$ или w_i , $w_i \in \Sigma^*$) является нормализованным, если выполняются следующие условия.

1. Среди компонент пересечения нет такой L_i , что $L_i \subseteq L_j$ для $i \neq j$ (отсутствие избыточности).
2. Не существует такого L_{n+1} , что $L = L \cap L_{n+1}$ и при этом не нарушено предыдущее условие (полнота представления).

Соответственно, для нормализации представления необходимо убрать компоненты, нарушающие первое условие, и добавить компоненты, нарушающие второе.

Отметим, что проверка отсутствия избыточности представления более тривиальна, чем поиск полноты представления.

Если язык является множеством-синглетоном, то нормализация избыточности его представления сводится к проверке остальных уравнений на подстроки этого элемента, иначе система противоречива, и язык эквивалентен пустому множеству. Иначе говоря, условия накладываемые на расширенный словарь в определении 9 обеспечивают отсутствие избыточности представления.

Для внутренней нормализации строкового свойства необходимо следующее утверждение, представленное в статье [АН архив] в терминах неизбежных подстрок. Приведем здесь переформулировку с альтернативным обоснованием, проиллюстрировав связь с известными свойствами класса LT-языков.

Будем использовать теорему 7 [зальстейн] о строении языка $L_u = \Sigma^* u \Sigma^*$ и ходом ее доказательства.

Теорема 1 (Зальстейн, теорема 7). Пусть $L_u = \Sigma^* u \Sigma^*$, $u \in \Sigma^+$. Следующие условия эквивалентны:

1. Либо $|\Sigma| \geq 3$, либо $\Sigma = \{a, b\}$ и u не имеет вида $a^n b$ или $a b^n$ ни для какого $n \geq 1$.
2. Минимальный ДКА $\mathcal{A}(L_u)$, распознающий L_u , является *почти сильно связным* (0-транзитивным): у него есть поглощающее (и единственное допускающее) состояние d , и для любых двух состояний $q', q'' \in Q \setminus \{d\}$ найдётся такое слово $v \in \Sigma^*$, что $q' \cdot v = q''$.
3. Синтаксическая полугруппа $\mathcal{S}(L_u)$ — нильпотентное расширение конечного 0-простого комбинаторного идеала.

Будем использовать обозначение $u[i : j]$ для подстроки u от индекса i до индекса j включительно (первый символ строки имеет индекс 1).

В ходе доказательства теоремы 1 используется следующая лемма.

Лемма 1 (Зальстейн, лемма 2). Пусть $u = u_1 u_2 \dots u_m \in \Sigma^+$, $L_u = \Sigma^* u \Sigma^*$ как в теореме 1, и $\mathcal{A}(L_u)$ — минимальный ДКА, распознающий L_u , с множеством со-

стояний $Q = \{q_0, q_1, \dots, q_m\}$, причём $q_i = q_0 u[1 : i]$ для $1 \leq i \leq m$, а $q_m = d$ — поглощающее допускающее состояние. Тогда для всякого состояния q_i ($i < m$) и любого слова $v \in \Sigma^+$ верно:

- $q_i v = d$ тогда и только тогда, когда u является подсловом строки $u[1 : i]v$;
- в противном случае $q_i v = q_j$, где $u[1 : j]$ — наибольший по длине префикс u , являющийся суффиксом строки $u[1 : i]v$.

Будем использовать вышеприведенные утверждения для обоснования следующего утверждения о полноте представления.

Утверждение 1. Пусть L — язык вида, представленного в задаче нормализации строкового свойства, в котором выполнено условие отсутствия избыточности. Тогда,

- если $|\Sigma| > 2$, свойство полноты представления всегда выполняется;
- если $|\Sigma| = 2$, свойство полноты представления могут нарушать только компоненты вида $\Sigma^* a b^n \Sigma^*$ и $\Sigma^* b^n a \Sigma^*$ ($\Sigma = \{a, b\}$).

Доказательство. 0. Отметим, что компоненты вида $w_i \Sigma^*$, $\Sigma^* w_i$ и w_i не могут нарушать свойство полноты представления.

1. Пусть строковое свойство задает язык $L = \bigcap_{i=1}^n \Sigma^* w_i \Sigma^* \cap p \Sigma^* \cap \Sigma^* s$ (здесь p и/или s , возможно, пустые строки, т.е. ограничений на префикс и суффикс может не быть). Предположим, что u — некоторый фактор, не являющийся подстрокой ни в p , ни в s , ни в w_i для любого i , что $L_u = \Sigma^* u \Sigma^*$ нарушает свойство полноты представления.

1.1. Рассмотрим случай, когда L_u — как в теореме 1. По предположению, любое слово w языка L должно быть принято $\mathcal{A}(L_u)$.

Согласно лемме 1, которая используется в статье для доказательства теоремы 1, для $v \in \Sigma^+$ $q_i v = d \iff u$ — подстрока $u[1 : i]v$. Поскольку изначально u не является подстрокой ни в p , ни в s , ни в w_i , из леммы получаем, что s , p и все w_i по отдельности не могут быть приняты ДКА $\mathcal{A}(L_u)$.

Из теоремы 1 следует, что $\exists v_j : q_j v_j = q_0$, $j \leq m - 1$. Так как $q_0 p \neq d$, $q_0 s \neq d$ и $q_0 w_i \neq d$, для всех i , $\exists v_p, v_1, \dots, v_n : q_0 p v_p = q_0$, $q_0 w_i v_i = q_0$, $i \leq n$.

Это отражение того, что автомат связный, если убрать допускающее (поглощающее) состояние d . Т.е. пока мы не прочитаем u как подстроку полностью, мы можем некоторым образом вернуться в начальное состояние.

Сконструируем слово

$$w = pv_p w_1 v_1 \dots w_n v_n s.$$

По конструкции видно, что $w \in L$ и по предположению оно принимается $\mathcal{A}(L_u)$.

Но $q_0 w = q_0 pv_p w_1 v_1 \dots w_n v_n s = q_0 w_1 v_1 \dots w_n v_n s = \dots = q_0 w_n v_n s = q_0 s$, и при этом $q_0 s \neq d$. Получаем противоречие, из чего следует вывод, что языки, описанные в теореме 1, не могут нарушать свойство полноты представления.

1.2. Пусть $\Sigma = \{a, b\}$.

1.2.А. Пусть $u = ab^m$. Тогда если найдутся w_i, w_j , удовлетворяющие регулярному выражению $b^*a(a|b)^+b^m$ и не содержащие u как подстроку, то u обязательно содержится во всех словах L .

1.2.Б. Пусть $u = a^m b$. Тогда если найдутся w_i, w_j , удовлетворяющие регулярному выражению $a^*b(a|b)^*a^m$ и не содержащие u как подстроку, то u обязательно содержится во всех словах L .

С точностью до переименования символов, получаем описания некоторых случаев, когда u определенного утверждением вида действительно нарушает свойство полноты представления и может быть добавлено в представление языка L .

□

Случаи, когда компонента вида $\Sigma^*ab^m\Sigma^*$ (или $\Sigma^*a^mb\Sigma^*$) в двухбуквенном алфавите может быть добавлена в представление языка L , описаны в доказательстве утверждения 1 довольно широко, но не полностью, поскольку не рассмотрены варианты, когда префикс или суффикс (возможно, совместно с некоторой подстрокой) вызывают необходимость пополнения представления языка L .

Пример 1. Пусть $L = \{aa\Sigma^*b\}$ и $\Sigma = \{a, b\}$. Тогда aab также содержится во всех словах L .

Пример 2. Пусть $L = \Sigma^*abbb\Sigma^* \cap \Sigma^*baa\Sigma^* \cap \Sigma^*ab$, $\Sigma = \{a, b\}$. Тогда слова $bbba$ и aab также содержатся во всех словах L .

3 LTL-свойства

Необходимо различать язык, который задает система уравнений сама по себе и язык, который задается строковым свойством. Как было уже отмечено ранее, язык строкового свойства задается как $\mathcal{L}((\sigma, E)) = \sigma^{-1}(\mathcal{L}(E))$. В системе уравнений используется ограниченный алфавит, поэтому он описывает лишь проекцию языка свойства на множество строк в алфавите $\Sigma' = im(\sigma|_{\Sigma}) \setminus \{\varepsilon\}$.

Для тождественного отображения язык строкового свойства совпадает с языком его системы уравнений — значения строкового объектов. Как будет показано далее, локально тестируемые языки удобны для анализа, поэтому имеет место вопрос, задает ли строковое свойство LT язык. В этом случае строковое свойство действует в некотором смысле как система уравнений (поскольку сами системы задают LT языки).

Для дальнейшего рассуждения будем использовать теорему о характеристизации LT-языков [McNaughton; Brzozowski, Simon; Caron, теорема 2.5].

Теорема 2 (Caron, теорема 2.5). Пусть $L \subseteq \Sigma^+$ — регулярный язык. Следующие условия эквивалентны:

1. L — локально тестируемый (LT) язык.
2. Синтаксическая полугруппа $\mathcal{S}(L)$ языка L локально идемпотентна и коммутативна, то есть для всякого идемпотента $e \in E(\mathcal{S}(L))$ подполугруппа $e\mathcal{S}(L)e$ идемпотентна и коммутативна.

Утверждение 2. Строковое свойство (σ, E) задает LT язык тогда и только тогда, когда верно одно из следующего:

- $|im(\sigma|_{\Sigma})| = 1$;
- $im(\sigma|_{\Sigma}) = \{\alpha, \varepsilon\}$ и E содержит только уравнения вида $Z = X\alpha Y$, $Z = X\alpha$, $Z = \alpha Y$;
- σ — нестирающий морфизм;
- σ — стирающий морфизм, E — система уравнений, имеющая только уравнения вида $Z = X_i\alpha_i Y_i$, где $\alpha_i \in im(\sigma|_{\Sigma})$.

Доказательство. Отметим, что для случая $|im(\sigma)| = 1$ свойство задает LT язык, поскольку в этом случае $im(\sigma|_{\Sigma}) = \{\alpha\}$ или $im(\sigma|_{\Sigma}) = \{\varepsilon\}$. Вторая альтернатива

тривиальна, а в первом случае это свойство задает ограничение лишь на длину строки.

1. Пусть σ — нестирающий морфизм.

1.1. Если $E = \{Z = c\}$, то, поскольку алфавит конечный, $\mathcal{L}((\sigma, E)) = \sigma^{-1}(c) = \bigcup_{i=1}^n \{c_i\}$, $c_i \in \Sigma^+$, что дает LT язык.

1.2. Система уравнений не представляет собой константное уравнение. Зададим отображение уравнения во множество строк, которое оно задает в данном строковом свойстве.

$$Z = XwY \mapsto \Sigma^* \sigma^{-1}(w) \Sigma^*$$

$$Z = Xw \mapsto \Sigma^* \sigma^{-1}(w)$$

$$Z = wY \mapsto \sigma^{-1}(w) \Sigma^*$$

Очевидно, что множество строк, задаваемых уравнением каждого вида — LT язык, а следовательно их пересечение также является LT языком.

2. Пусть σ — стирающий морфизм, $im(\sigma|_{\Sigma}) \neq \{\varepsilon\}$.

Для доказательства далее будем использовать алгебраическую характеристику LT языков (теорема 2):

Будем обозначать $[w]$ — элемент синтаксической полугруппы $\mathcal{S}(L)$, соответствующий строке $w \in \Sigma^+$.

Поскольку язык задается строковым свойством, то определение синтаксической конгруэнции $\sim_L$ можно эквивалентно переписать так:

$$u \sim_L v \text{ если } \forall x, y \in \Sigma^+ \sigma(xuv) \text{ удовлетворяет системе } E \iff \sigma(xvy) \text{ удовлетворяет системе } E.$$

Пусть $\sigma(\gamma) = \varepsilon$. Тогда $[\gamma]$ — идемпотент в $\mathcal{S}(L)$.

2.1. Покажем, что случай $E = \{Z = c\}$ не дает LT язык. $[\gamma c \gamma]$ не является идемпотентом в $[\gamma] \mathcal{S}(L) [\gamma]$, поскольку $\gamma c \gamma \not\sim_L \gamma c \gamma \gamma c \gamma$.

2.2. Иначе рассматриваем неконстантные системы уравнений.

Пусть A — множество символов, встречающихся в строках системы уравнений, $A \subseteq im(\sigma|_{\Sigma}) \setminus \{\varepsilon\} \subseteq \Sigma$.

2.2.1. $|A| = 1, A = \{\alpha\}$. По предположению о локальной тестируемости языка, верно следующее:

$$\begin{aligned} [\gamma\alpha\gamma][\gamma\alpha\gamma] &= [\gamma\alpha\gamma] \\ [\gamma\alpha\alpha\gamma][\gamma\alpha\alpha\gamma] &= [\gamma\alpha\alpha\gamma] \end{aligned}$$

Тогда для натурального n $\alpha^n \in L$ и $\alpha \sim_L \alpha^n$, отсюда следует, что ограничения могут быть только однобуквенными. Тогда система уравнений имеет вид $\{Z = \alpha X_1; Z = X_2 \alpha\}$, или $\{Z = X\alpha\}$, или $\{Z = \alpha X\}$, или $\{Z = X\alpha Y\}$.

1. $\{Z = X\alpha Y\}$: является ЛТ языком, а именно $\Sigma^* \sigma^{-1}(\alpha) \Sigma^*$.
2. $\{Z = \alpha X_1; Z = X_2 \alpha\}$: для $im(\sigma|_\Sigma) = \{\alpha, \varepsilon\}, \gamma \mapsto \varepsilon$ язык является ЛТ (а именно $(\sigma^{-1}(\varepsilon)\sigma^{-1}(\alpha)\sigma^{-1}(\varepsilon))^+ = A^+ \setminus \sigma^{-1}(\varepsilon)$); если $\exists \beta \mapsto \beta$, язык не является ЛТ (контрпример: слова $\gamma^k \alpha \gamma^k \beta \gamma^k$ и $\gamma^k \alpha \gamma^k \beta \gamma^k \alpha \gamma^k$ имеют одинаковые k -подстроки, но первое не принадлежит языку).
3. $\{Z = \alpha X\}$ рассуждение аналогично предыдущему пункту.
4. $\{Z = X\alpha\}$: полностью симметрично предыдущему пункту.

2.2.2. $|A| > 1, A = \{\alpha_1, \dots, \alpha_n\}, \sigma(\alpha_i) = \alpha_i$.

Аналогично рассуждению выше, из коммутативности и идемпотентности

$$\alpha_i \alpha_i \sim_L \alpha_i, \quad \alpha_i \alpha_j \sim_L \alpha_j \alpha_i$$

.

Пусть $w = \alpha_{k_1} \dots \alpha_{k_m} \in A^+$, $k_j \in \{1, \dots, n\}$, w — минимальная по длине строка, удовлетворяющая системе уравнений (minimal common superstring). Тогда $w \sim_L \alpha_{i_1} \alpha_{i_2} \dots \alpha_{i_m}, (i_1, \dots, i_m)$ — такая перестановка множества $\{k_1, \dots, k_m\}$, где если $\alpha_{i_j} = \alpha_{i_{(j+s)}}$, то $\forall t \leq s, t \geq 0 \alpha_{i_{(j+t)}} = \alpha_{i_j}$.

Воспользовавшись свойством идемпотентности для соседних символов, получаем $w \sim_L w' = \alpha_{p_1} \alpha_{p_2} \dots \alpha_{p_r}, \alpha_{p_i}$ — различные символы, $r \leq m$.

2.2.2.A. Покажем, что для случая подстрок длины ≥ 2 в оставшемся подслучае язык не является ЛТ.

Если в системе уравнений есть уравнения с подстроками (с префиксами или суффиксами) длины 2 или более, то верно одно из двух:

1. $|w'| < |w|$ и, так как w — минимальная строка, w' не удовлетворяет системе уравнений, т.е. $w' \not\sim_L w$.
2. $|w'| = |w|$, $w' \sim_L w$, w' — одна из минимальных строк, удовлетворяющих системе уравнений.

Слово w' содержит только различные символы, значит в уравнении системы с подстрокой длины ≥ 2 будут использоваться различные символы, условно α_a, α_b . Сконструируем слово w'' , полученное из w' перестановкой α_a и α_b . Поскольку сочетание $\alpha_a \alpha_b$ теперь не встречается в w' , то получаем противоречие: $w' \not\sim_L w$.

2.2.2.Б. Покажем утверждение теоремы для систем, содержащих уравнения только вида $Z = X\alpha_i Y$, $Z = X\alpha_j$, $Z = \alpha_k Y$.

Заметим, что наличие уравнений на префикс или суффикс выводит язык из класса LT. Пусть есть уравнение $Z = \alpha_{p_1} W$, и w' удовлетворяет системе уравнений. По построению $\alpha_{p_2} \neq \alpha_{p_1}$, значит $w'' = \alpha_{p_2} \dots \alpha_{p_r} \alpha_{p_1} \not\sim_L w'$. Симметричное рассуждение проводится и для суффикса.

Для систем, состоящих только из уравнений вида $Z = X\alpha Y$, легко видеть, что задаваемый их строковым свойством язык является LT.

$$\mathcal{L}((\sigma, \{Z = X\alpha Y\})) = \Sigma^* \sigma^{-1}(\alpha) \Sigma^*$$

$$L = \mathcal{L}((\sigma, E)) = \bigcap_{i=1}^k \Sigma^* \sigma^{-1}(\alpha_{p_i}) \Sigma^*$$

Таким образом, покрыв рассуждением все языки, задаваемые строковыми свойствами, получаем утверждение теоремы. □

4 Стандартные и монотонные морфизмы

Зададим следующие операции на классе стандартных морфизмов:

$$(f \sqcap g)(x) = \min(f^{-1}(f(x)) \cap g^{-1}(g(x))) \quad (\text{meet}); \quad (3)$$

$$(f \sqcup g)(x) = \min[x]_{f,g} \quad (\text{join}). \quad (4)$$

Здесь $[x]_{f,g}$ — класс эквивалентности отношения $\sim_{f,g}$, которое задается для пары морфизмов f, g следующим образом:

$$x \sim_{f,g} f(x) \wedge x \sim_{f,g} g(x) \text{ для всех } x. \quad (5)$$

Утверждение 3. Операции join и meet (соотношения 3 и 4) задают решетку на стандартных морфизмах. Эти операции согласованы с частичным порядком из определения 3.

Доказательство. Покажем корректность операций относительно порядка.

1.1. $f \sqcap g \preceq f$. Действительно, $(f \sqcap g)(x) \in f^{-1}(f(x))$, значит $f((f \sqcap g)(x)) = f(x)$ для всех x .

$$1.2. g \preceq f \iff f \sqcap g = g.$$

($\Rightarrow$). Пусть $f(g(x)) = f(x)$, тогда, т.к. $g(g^{-1}(g(x))) = g(x)$, то $f(g(g^{-1}(g(x)))) = f(g^{-1}(g(x))) = f(g(x)) = f(x)$, т.е. $f^{-1}(f(x)) \supseteq g^{-1}(g(x))$ (это соответствует тому, что разбиение алфавита в меньшем морфизме всегда вкладывается в разбиение алфавита в большем морфизме).

Отсюда следует, что $f^{-1}(f(x)) \cap g^{-1}(g(x)) = g^{-1}(g(x))$, что доказывает первую часть утверждения.

($\Leftarrow$). Из определения операции получаем вложение $f^{-1}(f(x)) \supseteq g^{-1}(g(x))$ (иначе для элементов вне пересечения поведение meet-морфизма отличалось бы от g). Далее, $f(g(g^{-1}(g(x)))) = f(x)$, т.е. $f(g(g(x))) = f(g(x)) = f(x)$.

2.1. $f \sqcup g \succeq f$. Действительно, $f(x) \in [x]$, значит $(f \sqcup g)(f(x)) = (f \sqcup g)(x)$ для всех x .

$$2.2. g \preceq f \iff f \sqcup g = f.$$

($\Rightarrow$). Пусть $f(g(x)) = f(x)$. Выше обосновано, что $f^{-1}(f(x)) \supseteq g^{-1}(g(x))$, поэтому $[x] = f^{-1}(f(x))$, значит $\min[x] = f(x)$.

($\Leftarrow$). Равенство означает, что $[x]_{f,g} = f^{-1}(f(x))$, значит $f(x) \sim_{f,g} x \sim_{f,g} y \in g^{-1}(g(x))$, что снова приводит в вложению разбиений, и аналогично доказательству для meet снова приводит к требуемому утверждению.

3. Идемпотентность, коммутативность, ассоциативность обеих операций следует из их определения и определения стандартного морфизма.

4. Поскольку уже показана согласованность порядка с операциями, законы поглощения обосновать несложно. Поскольку $f \succeq (f \sqcap g)$, то $f \sqcup (f \sqcap g) = f$. Полностью по аналогии $f \sqcap (f \sqcup g) = f$. $\square$

Рассмотрим класс монотонных стандартных нестирающих морфизмов. А именно, зафиксировав алфавит Σ , снабженный линейным порядком, монотонный морфизм — морфизм, удовлетворяющий свойству $\forall a, b \in \Sigma, a \leq b \implies \sigma(a) \leq \sigma(b)$.

Поскольку Σ — линейно упорядоченное множество, то верно и следующее: если $\sigma(a) < \sigma(b)$, то $a < b$ для всех $a, b \in \Sigma$.

Монотонные стандартные нестирающие морфизмы не имеют «разорванных» разбиений, т.е. для любого Σ_i все элементы алфавита в диапазоне (согласно линейному порядку) от $\min(\Sigma_i)$ до $\max(\Sigma_i)$ также входят в Σ_i .

Утверждение 4. Порядок на стандартных морфизмах $\preceq$, заданный ранее ($\sigma \preceq \tau \iff \tau \circ \sigma = \tau$), для множества монотонных стандартных нестирающих морфизмов эквивалентен порядку $\preceq_M$, заданному следующим образом:

$$\sigma \preceq_M \tau \iff \forall x \in \Sigma, \tau(x) \preceq \sigma(x).$$

Доказательство. Для доказательства приведем явную проверку эквивалентности

$$\tau \circ \sigma = \tau \iff \forall x \in \Sigma, \tau(x) \leq \sigma(x).$$

$\implies$. $\tau(\sigma(x)) = \tau(x)$ для всех $x \in \Sigma$. По определению стандартного морфизма $\tau(x) \leq x$, подставляя аргумент — $\tau(x) = \tau(\sigma(x)) \leq \sigma(x)$.

$\impliedby$. $\tau(x) = \tau(\tau(x)) \leq \tau(\sigma(x))$ с одной стороны. С другой: $\sigma(x) \leq x$, значит $\tau(\sigma(x)) \leq \tau(x)$. Поскольку это верно для всех $x \in \Sigma$, получаем требуемое равенство. $\square$

Добавление монотонности позволяет упростить вычисление операций join и meet для монотонных стандартных нестирающих морфизмов следующим образом:

$$(\sigma \sqcap \theta)(x) = \max(\sigma(x), \theta(x)) \quad (6)$$

$$(\sigma \sqcup \theta)(x) = (\sigma \circ \theta)^*(x) = (\theta \circ \sigma)^*(x), \quad (7)$$

здесь $\tau = (\sigma \circ \theta)^*$ — неподвижная (фиксированная) точка отображения $\sigma \circ \theta$.

Эти соотношения — монотонные аналоги соотношений 3 и 4.

Для конкретного аргумента x элементы разбиения двух морфизмов $\sigma^{-1}(\sigma(x))$ и $\theta^{-1}(\theta(x))$ непрерывны, пересекаются по непрерывному отрезку и при этом $\min \sigma^{-1}(\sigma(x)) = \sigma(x)$ (что верно и для θ). Поэтому минимальный элемент в пересечении прообразов — именно $\max(\sigma(x), \theta(x))$, что и задает операцию meet .

Для монотонных морфизмов класс эквивалентности $[x]_{f,g}$ содержит каждую точку на пути стабилизации отображения $x \mapsto \theta(x) \mapsto (\sigma \circ \theta)(x) \mapsto (\theta \circ \sigma \circ \theta)(x) \mapsto (\sigma \circ \theta \circ \sigma \circ \theta)(x) \mapsto \dots \mapsto \tau(x)$ и каждый переход этой цепочки невозрастающий. Это прямое следствие монотонности: если $\sigma(x) \leq \theta(x)$, то $\theta(\sigma(x)) \leq \theta(x)$ и при этом $\sigma(\theta(x)) \leq \sigma(x)$ (т.к. по определению стандартного морфизма $\theta(x) \leq x$); если же $\theta(x) \leq \sigma(x)$, рассуждаем симметрично.

Именно поэтому композиции $\sigma \circ \theta$ и $\theta \circ \sigma$ стабилизируются в одной точке для монотонных морфизмов. Для немонотонных морфизмов это неверно: утверждение $\sigma(x) \leq \theta(x) \implies \theta(\sigma(x)) \leq \theta(x)$ может не выполняться, что приведет к тому, что фиксированные точки композиций будут различаться, что в принципе нарушит условие присутствия точной верхней грани.

Пример 3. Пусть $\Sigma = \{a, b, c\}$ с линейным порядком $a < b < c$, и стандартные морфизмы σ, θ заданы следующим образом:

$$\sigma(a) = a, \sigma(b) = b, \sigma(c) = a, \theta(a) = a, \theta(b) = b, \theta(c) = b.$$

Тогда $\sigma \circ \theta = \theta$ и $\theta \circ \sigma = \sigma$.

Таким образом, поскольку эти морфизмы не монотонны, $(\sigma \circ \theta)^*$ и $(\theta \circ \sigma)^*$ будут различаться и, более того, не будут являться верхними гранями для σ и θ , поскольку они несравнимы.

Прямой проверкой также можно убедиться, что определение монотонного meet 6 для этой пары морфизмов также не даст точную нижнюю грань.

5 Кросс-нормализация

Строковые свойства — компоненты одного строкового объекта, рассматриваемые одновременно. Поэтому в явном виде множество строк, описываемых строковым объектом, можно описать пересечением языков всех его строковых свойств.

Определение 14. Кросс-нормализацией строкового свойства SP_1 относительно другого строкового свойства SP_2 называется добавление всех уравнений допустимого SP_1 вида, которые описывают язык $\mathcal{L}(SP_1) \cap \mathcal{L}(SP_2)$.

Каждое уравнение SP_2 описывает язык I_2 одного из видов: $\Sigma^* \sigma_2^{-1}(w) \Sigma^*$, $\Sigma^* \sigma_2^{-1}(w)$, $\sigma_2^{-1}(w) \Sigma^*$, $\sigma_2^{-1}(w)$.

Кросс-нормализация SP_1 относительно SP_2 решает задачу нахождения такого множества строк $I_1 \subseteq \Sigma^+$, что $\sigma_1(I_1) \supseteq \sigma_1(I_2)$, при этом $\sigma_1(I_1)$ является множеством строк, задаваемым уравнением (или уравнениями) одного из допустимых видов.

Неформально, это означает, что в систему уравнений SP_1 добавляются все возможные уравнения, которые также описывают пересечение языков SP_1 и SP_2 , поскольку строковые свойства для одного объекта имеют целью описать множество конкретизации объекта в разных «проекциях».

Из определения строкового свойства I_2 представляет собой объединение тривиальных компонент, тем временем $\sigma_1(I_1)$ должно иметь форму пересечения некоторых также тривиальных компонент. Тривиальные компоненты — левые, правые и двусторонние идеалы Σ^+ , а также множества-синглтоны из одной строки $\{w\}$. Кроме того, т.к. I_2 — язык одного конкретного уравнения, он является либо левым, либо правым, либо двусторонним идеалом, либо конечным множеством

строк. Покрывающее множество I_1 должно являться более объемлющим; к примеру, $\sigma_1(I_1)$ не может быть левым идеалом, если I_2 — язык уравнения на инфикс.

..... здесь будут соображения о том, что минимальный покрывающий идеал — пересечение ”подстроковых” идеалов для некоторых строк

Некоторая подстрока w будет задавать покрывающий идеал или константное уравнение только если выполняется следующее необходимое условие кросс-переноса (в SP_1 из SP_2):

$$\sigma_1(\sigma_2^{-1}(w)) \text{ — синглтон.} \quad (8)$$

Поскольку для строковых свойств, задающих LT языки, верно, что неконстантные уравнения задают либо левый, либо правый, либо двусторонний идеал, то и в обратную сторону, нахождение покрывающего идеала — достаточно простая задача. Однако это неверно для не-LTL свойств: каждое уравнение такого свойства задает регулярный, но не LT язык, что затрудняет нахождение нетривиального языка, представимого уравнением другого строкового свойства.

Более того, поскольку из LTL-свойств переносятся только некоторые сохраняемые относительно морфизмов подстроки, это позволяет передать максимум информации в сравнимые свойства. При этом в несравнимое с данным строковое свойство переносятся уравнения, которые также возможно перенести в некоторое сравнимое свойство. Для не-LTL свойств подобный механизм не работает из-за более сложной структуры языков.

Пусть в некотором уравнении строкового свойства используются только символы из $A \subseteq \Sigma$, тогда для не-LTL свойства в худшем случае найдется порядка $2^{|A|}$ несравнимых по морфизму строковых свойств (поскольку, опираясь на структуру уравнения, различные символы уравнения могут по-разному быть объединены в разбиении, что существенно влияет на структуру переносимых уравнений). Это отражено на рисунке ?? : на пунктирных стрелках подписаны подстроки, переносимые в несравнимое свойство.

Как было отмечено ранее, ни один из переносов в вышеприведенном примере не может быть совершен между данным и свойством со сравнимым с ним




Рисунок 1 — Нетривиальный перенос уравнений из не-LTL свойства в несравнимые по морфизму свойства

меньшим морфизмом. Для сравнимых стирающих морфизмов процесс кросс-переносов схож с кросс-переносом для LTL-свойств.

При этом из-за стирания структура переносимого уравнения более непредсказуема и зависит от конкретной системы уравнений (см. рисунок ??).




Рисунок 2 — Кросс-перенос из SP стирающего стандартного морфизма

В данном случае в свойство ниже по решетке морфизмов не может сохранить ту же информацию, что и кросс-перенос (даже для двух не-LTL свойств). В этом их отличие от свойств, задающих ЛТ языки.

Перенос в LTL-свойства из не-LTL-свойств создает трудности для редукции строкового объекта в целом: именно LTL-свойства в некотором смысле более устойчивы к сохранению информации при строковых операциях, обобщении и т.п. Появление порядка $2^{|A|}$ таких «спутников» создает сложность для анализа в целом, поскольку, если стремиться к точности, необходимо отслеживать также все эти свойства.

Утверждение 5. Для LTL-свойств $SP_1 = (S_1, \sigma_1)$ и $SP_2 = (S_2, \sigma_2)$ верно следующее: если уравнение $e \in S_2$ может быть перенесено в SP_1 , то e может быть перенесено в $(S_{meet}, \sigma_3 = \sigma_1 \sqcap \sigma_2)$.

При этом трансформация строки w уравнения e сохраняется: $\sigma_1(\sigma_2^{-1}(w)) = \sigma_1(\sigma_3(\sigma_2^{-1}(w)))$.

Доказательство. Пусть $\sigma_1(\sigma_2^{-1}(w)) = u$ — слово из уравнения, которое переносится в SP_1 .

$\sigma_3(\sigma_2^{-1}(w)) = \min[\sigma_1^{-1}(\sigma_1(\sigma_2^{-1}(w))) \cap \sigma_2^{-1}(\sigma_2(\sigma_2^{-1}(w)))] = \min(\sigma_1^{-1}(u) \cap \sigma_2^{-1}(w))$ и т.к. из посылки теоремы $\sigma_1^{-1}(u) \supseteq \sigma_2^{-1}(w)$, то $\sigma_3(\sigma_2^{-1}(w)) = \min(\sigma_2^{-1}(w)) = \sigma_2(w)$.

Дополнительное утверждение не требует отдельного обоснования, т.к. $\sigma_3 \preceq \sigma_1$ по определению. $\square$